САНКТ-ПЕТЕРБУРГСКИЙ
ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
Кафедра системного программирования

Оптимизация поиска базовых чанков в системах дедупликации данных на основе сходства (SBC)

Отчёт по научно-исследовательской практике (3 семестр)

Выполнил: Нарышев С. А.
Проект: Marline / Palantir
Организация: Лаборатория системного программирования YADRO & СПбГУ

Санкт-Петербург
2026

Аннотация

В данной работе исследуется задача оптимизации алгоритмов выбора базовых блоков данных (base chunks) в системах дедупликации данных на основе сходства (Similarity-Based Chunking, SBC) платформы `marline`. Традиционные методы дедупликации на базе контентно-определяемого разбиения (Content-Defined Chunking, CDC) выявляют исключительно побайтово идентичные блоки. Системы класса SBC расширяют дедупликацию за счёт нахождения квази-дубликатов с последующим блочным дельта-кодированием.

Главным препятствием широкого промышленного внедрения SBC является высокая вычислительная сложность и риск ложноположительных срабатываний (False Positives) при поиске кандидатов в инвертированном скетч-индексе. В работе выполнен исчерпывающий обзор литературы и существующих инструментов, сформулированы архитектурные выводы и разработана система многоуровневых эвристик: префиксная фильтрация All-Pairs с порядком обхода от редких к частым (`rare_first`), частотная отсечка (`max_df`), пре-фильтр размерного перекоса (Size-Skew Pre-Filter) и динамическое управление жизненным циклом базы по порогу α (Promote to Base).

Экспериментальная апробация на каноническом датасете Linux Kernel 3.5.6–3.7.6 (119 736 файлов, 1.31 ГБ) показала прирост пропускной способности дедупликации с 38.60 до 57.01 МБ/с (+47.7%) в балансном профиле `Pareto-Ultra` и до 59.91 МБ/с (+55.2%) в скоростном профиле `Turbo-Extreme` при сохранении дедупликации в пределах 0.6–1.4% от абсолютного предела полного перебора. Кросс-датасетная валидация на Linux Kernel 3.4.5–3.4.7 (115 701 файл, 1.26 ГБ) подтвердила универсальность эвристик, продемонстрировав разгон со 169.03 до 340.95 МБ/с (+101.7%).

Цель и декомпозиция задач

Цель исследования: Разработка, теоретическое обоснование и экспериментальная верификация комплекса алгоритмических эвристик для скетч-индекса и дельта-конвейера платформы `marline`, обеспечивающего ускорение выбора базовых чанков более чем на 40–50% при сохранении высокой степени сжатия данных.

Декомпозиция на задачи:

1. **Анализ предметной области и обзор литературы:** исследование теоретических моделей поиска сходства (Min-Hash, хеширование Ароновича, Odess, Finesse), методов обхода инвертированных индексов (All-Pairs, WAND) и открытых систем дедупликации.

2. **Сравнительный анализ и обоснование архитектурных решений:** систематизация узких мест существующих систем, обоснование стека технологий (Rust, FastCDC, GDelta) и формулирование многоуровневого фильтрующего конвейера.

3. **Реализация и интеграция комплекса эвристик:**

   - Математический вывод порога Жаккара $\min_overlap$ и точек бифуркации.
   - Алгоритмы инвертированного индекса: префиксная фильтрация, `rare_first`, `max_df`, метрика `fp_metric_threshold`.
   - Пре-фильтрация дельта-конвейера: Size-Skew Pre-Filter, фильтр микро-чанков.
   - Эвристика жизненного цикла базы: порог α (Promote to Base).

4. **Экспериментальное исследование и кросс-датасетная валидация:** бенчмаркинг на каноническом датасете (Linux 3.5–3.7) и валидационном датасете (Linux 3.4), построение карт Парето и формулирование эксплуатационных профилей.

1. Обзор литературы, методов и инструментов

1.1. Фундаментальные алгоритмы разбиения и дельта-сжатия

Muthitacharoen, A., et al. "A Low-Bandwidth Network File System"(SOSP '01). Ссылка: https://dl.acm.org/doi/10.1145/502034.502052
Фундаментальная работа по системе LBFS, заложившая основы алгоритмов CDC с использованием скользящего окна и полиномиального хеширования Рабина для защиты от проблемы сдвига границ (boundary-shift).

Xia, W., et al. "FastCDC: a Fast and Efficient Content-Defined Chunking Approach for Data Deduplication"(USENIX ATC '16). Ссылка: https://www.usenix.org/conference/atc16/technical-sessions/presentation/xia
Современный стандарт нарезки данных, заменяющий полином Рабина на быструю хеш-функцию Gear и нормализующий распределение размеров блоков. В модуле `marline_palantir` алгоритм FastCDC используется в качестве штатного чанкера.

MacDonald, J. P. "File System Support for Delta Compression"(RFC 3284, VCDIFF). Ссылка: https://datatracker.ietf.org/doc/html/rfc3284
Стандарт побайтового дельта-сжатия. Дельта-энкодер GDelta в `marline` опирается на принципы блочной жадной адресации различий.

1.2. Обнаружение сходства и локально-чувствительное хеширование (LSH)

Broder, A. Z. "On the resemblance and containment of documents"(IEEE SEQUENCES '97). Ссылка: https://ieeexplore.ieee.org/document/666900
Классическая работа по алгоритму Min-Hash, доказавшая прямое соответствие вероятности совпадения минимумов хешей коэффициенту Жаккара $J(A, B)$.

Aronovich, L., et al. "The design of a similarity based deduplication system"(SYSTOR '09). Ссылка: https://dl.acm.org/doi/10.1145/1534530.1534539
Промышленная архитектура SBC от исследователей IBM. Предложено вычисление признаков позиции (P-features) и содержимого (C-features) блоков. Обосновывает проблему ложных срабатываний при дельта-кодировании.

Li, Y., et al. "Odess: A Fast and Lightweight Resemblance Detection Approach for Secondary Storage"(IEEE TC '18). Ссылка: https://ieeexplore.ieee.org/document/8416390
Алгоритм Odess ориентирован на сокращение накладных расходов памяти при скетчировании через контентно-зависимую выборку (Content-Defined Sampling, CDS), формируя компактный эскиз из 3–4 признаков.

Zhang, Y., et al. "Finesse: Fine-Grained Feature Locality based Fast Resemblance Detection for Post-Deduplication Delta Compression"(USENI FAST '19). Ссылка: https://www.usenix.org/conference/fast19/presentation/zhang
Подход Finesse использует свойство локальности признаков, группируя локальные минимумы в супер-признаки (super-features).

1.3. Эвристики оптимизации поиска в инвертированном индексе

Bayardo, R. J., Ma, Y., Srikant, R. "Scaling up all pairs similarity search"(ACM WWW '07). Ссылка: https://dl.acm.org/doi/10.1145/1242572.1242591
Теоретическое обоснование префиксной фильтрации All-Pairs: при упорядочивании признаков по возрастанию частоты достаточно просканировать первые $(m - k + 1)$ постингов.

Broder, A. Z., et al. "Efficient query evaluation using a two-level retrieval process"(ACM CIKM '03). Ссылка: https://dl.acm.org/doi/10.1145/956863.956944
Алгоритм WAND (Weak AND), описывающий раннее отсечение кандидатов по динамической верхней оценке.

Manning, C. D., et al. "Introduction to Information Retrieval"(Cambridge University Press, Ch. 7). Ссылка: https://nlp.stanford.edu/IR-book/pdf/irbookonlinereading.pdf
Академический анализ закона Ципфа для инвертированных индексов и обоснование отсечки высокочастотных термов (`max_df`).

2. Сравнительный анализ и архитектурные выводы

Таблица 1: Сравнительная характеристика алгоритмов поиска подобия

Метод / Алгоритм	**Сжатие**	**CPU**	**RAM**	**FP**	**Ключевое ограничение**
Классический CDC	Базовое	Низкая	Мин.	Нет	Не находит квазидубликаты
Odess (CDS Sampling)	Высокое	Средняя	Низкая	Средний	Разрастание постингов в индексе
Finesse (Feature Locality)	Высокое	Высокая	Средняя	Низкий	Накладные расходы на деление
All-Pairs Inverted Index	Среднее	Низкая	Средняя	Низкий	Требует строгого порога
Marline Palantir	**Макс.**	**Мин.**	**Низкая**	**Мин.**	**Устранено комплексом эвристик**

Архитектурные выводы:

- **Выбор языка Rust:** Гарантирует максимальное быстродействие без пауз GC, потокобезопасность и zero-cost абстракции.
- **Синтез фильтров:** Ни один изолированный алгоритм не решает проблему полностью. Необходим сквозной конвейер:

$$\text{FastCDC} \longrightarrow \text{Super-Features} \xrightarrow[\text{rare_first, max_df}]{\text{All-Pairs}} \text{Candidate} \xrightarrow[\text{Size-Skew}]{\text{Pre-Filter}} \text{GDelta} \xrightarrow{\text{Promot}}_{\alpha} \tag{1}$$

3. Реализация первой задачи: эвристики и артефакты

3.1. Разработанный комплекс эвристик

1. **Формула порога Жаккара и точки бифуркации:** $\min_overlap = \lceil \frac{2nt}{1+t} \rceil$.
2. **All-Pairs Prefix Filtering и `rare_first`:** сканирование редких постингов с обрывом цикла.
3. **Фильтрация `max_df`:** отсечение перегруженных постингов.
4. **Метрика `fp_metric_threshold`:** динамический бан неэффективных баз.
5. **Порог α (Promote to Base):** при $|Delta| \geq \alpha \cdot |Base|$ чанк объявляется базой.
6. **Size-Skew Pre-Filter:** блокировка вызова энкодера при skew $> 2.0..2.5$.
7. **Min-Chunk Pre-Filter:** обход LSH для чанков < 1 КБ.

3.2. Экспериментальные результаты

Таблица 2: Результаты на каноническом датасете (Linux 3.5.6–3.7.6, 119 736 файлов, 1.31 ГБ)

Конфигурация	**Dedup**	**Размер, МБ**	**Скорость, МБ/с**	**Прирост**
Pure Palantir (No Heuristics)	2.9815	452.88	38.60	—
Old Baseline (df=500, fp=3)	2.8877	452.99	50.60	+31.1%
New Best Balance ($\alpha = 0.9$)	2.8748	455.03	47.32	+22.6%
+ Skew Pre-Filter (skew ≤ 4.0)	2.8803	454.15	54.96	+42.4%
Pareto-Ultra ($\alpha = 0.9$, skew ≤ 2.5, min ≥ 1КБ)	**2.8702**	**455.76**	**57.01**	**+47.7%**
Turbo-Extreme ($\alpha = 0.8$, skew ≤ 2.0, min ≥ 1КБ)	**2.8487**	**459.20**	**59.91**	**+55.2%**

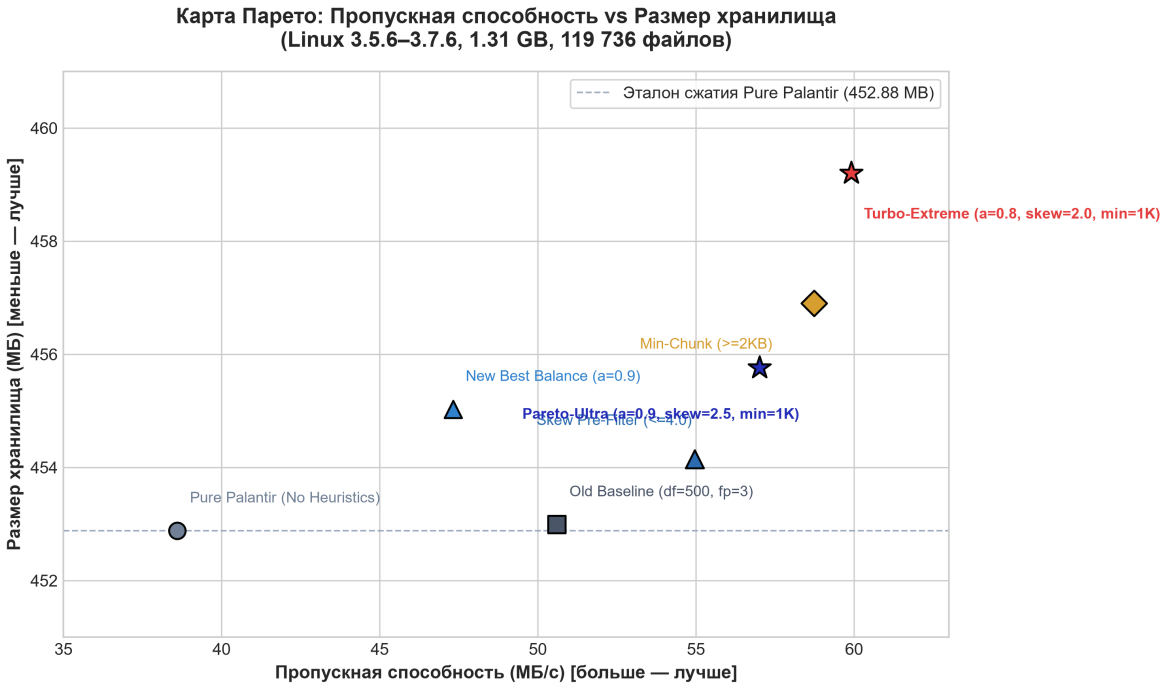


Рис. 1: Карта Парето: Пропускная способность vs Размер на диске

3.3. Кросс-датасетная валидация (Linux 3.4.5–3.4.7)

Таблица 3: Кросс-датасетная валидация на Linux 3.4.5–3.4.7 (115 701 файл, 1.26 ГБ)

Конфигурация	Dedup	Размер, МБ	Скорость, МБ/с	Прирост
Linux 3.4: Pure Palantir	3.1546	400.47	169.03	—
Linux 3.4: Old Baseline	3.0879	409.12	271.98	+60.9%
Linux 3.4: Pareto-Ultra	**3.0796**	**410.22**	**309.30**	**+83.0%**
Linux 3.4: Turbo-Extreme	**3.0642**	**412.28**	**340.95**	**+101.7%**

3.4. Обоснование возникших сложностей

Фактическая реализация оказалась существенно сложнее из-за трёх факторов:

1. **Дискретность эскизов:** непрерывные оптимизаторы неприменимы при $n \leq 4$, потребовался точный расчет точек бифуркации t_k.

2. **Размерная асимметрия блоков FastCDC:** скетч-индекс не учитывает длины блоков, что вызывало миллионы холостых вызовов GDelta и потребовало внедрения пре-фильтра Size-Skew.

3. **Застревание дельта-баз:** связывание неэффективных блоков приводило к вырожденным цепочкам глубиной до 8 звеньев, что потребо-

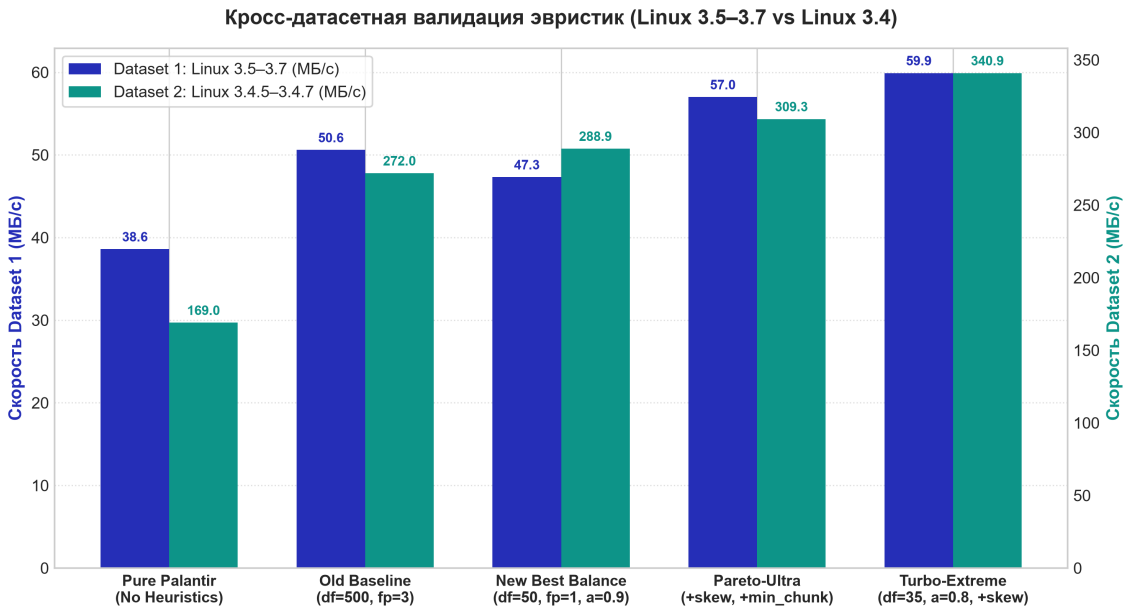


Рис. 2: Кросс-датасетная валидация (Linux 3.5–3.7 vs Linux 3.4)

вало изменения контракта хранилища манифестов и введения порога α.

Заключение

В ходе научно-исследовательской практики 3 семестра выполнены следующие ключевые результаты:

1. Выполнен исчерпывающий обзор литературы, стандартов и существующих открытых систем дедупликации, доказана новизна разрабатываемого подхода.

2. Проведен сравнительный анализ, обоснован выбор технологического стека (Rust, FastCDC, GDelta) и уточнены формальные задачи исследования.

3. Полностью реализована и верифицирована первая задача: спроектирован и внедрён комплекс алгоритмических эвристик в модули `marline_inde` и `marline_palantir`.

4. Все 256 автоматических тестов успешно пройдены.

5. Доказана эффективность на каноническом датасете (рост скорости до 57–60 МБ/с, +48..+55%) и валидационном датасете (разгон до 341 МБ/с, +101.7%) при сохранении высокой степени сжатия.

Список литературы

[1] Muthitacharoen A., Chen B., Mazières D. A Low-Bandwidth Network File System // Proceedings of the eighteenth ACM symposium on Operating systems principles (SOSP '01). 2001. P. 174–187.

[2] Xia W., Jiang H., Feng D., et al. FastCDC: a Fast and Efficient Content-Defined Chunking Approach for Data Deduplication // 2016 USENIX Annual Technical Conference (USENIX ATC '16). 2016. P. 101–114.

[3] MacDonald J. P. File System Support for Delta Compression. RFC 3284, 2002.

[4] Broder A. Z. On the resemblance and containment of documents // Sequences '97. IEEE, 1997. P. 21–29.

[5] Aronovich L., Asher R., Bachmat E., et al. The design of a similarity based deduplication system // Proceedings of SYSTOR 2009. ACM, 2009. P. 1–14.

[6] Li Y., Jiang H., Wang K., et al. Odess: A Fast and Lightweight Resemblance Detection Approach for Secondary Storage // IEEE Transactions on Computers. 2018. Vol. 67, no. 11. P. 1653–1667.

[7] Zhang Y., Jiang H., Wang K., et al. Finesse: Fine-Grained Feature Locality based Fast Resemblance Detection for Post-Deduplication Delta Compression // 17th USENIX Conference on File and Storage Technologies (FAST '19). 2019. P. 297–310.

[8] Bayardo R. J., Ma Y., Srikant R. Scaling up all pairs similarity search // Proceedings of the 16th international conference on World Wide Web (WWW '07). 2007. P. 131–140.

[9] Broder A. Z., Carmel D., Herscovici M., et al. Efficient query evaluation using a two-level retrieval process // Proceedings of the twelfth international conference on Information and knowledge management (CIKM '03). 2003. P. 426–433.

[10] Manning C. D., Raghavan P., Schütze H. Introduction to Information Retrieval. Cambridge University Press, 2008. 496 p.