Оптимизация поиска базовых чанков в системах дедупликации данных на основе сходства (SBC)

Задание 1: Содержательный обзор литературы, статей, подходов и инструментов

Введение

Дедупликация данных — фундаментальный метод оптимизации вторичных систем хранения, резервного копирования и архивных репозиториев, ориентированный на исключение избыточных копий блоков информации. Классическая схема дедупликации на основе контентно-определяемого разбиения (Content-Defined Chunking, CDC) устраняет исключительно побайтово идентичные блоки. Однако в распределённых хранилищах версий исходного кода, резервных копиях виртуальных машин и базах данных значительная часть блоков подвергается небольшим точечным модификациям (сдвигам, заменам строк, инкрементам счетчиков). Для сжатия таких блоков применяется дедупликация на основе сходства (Similarity-Based Chunking, SBC), сочетающая поиск близких блоков-кандидатов (base chunks) с последующим дельта-кодированием.

Ниже приведён содержательный анализ ключевых теоретических, алгоритмических и практических источников, определяющих современное состояние предметной области и демонстрирующих существующие подходы к решению поставленной задачи.

1. Базовые алгоритмы декомпозиции данных и дельта-компрессии

Muthitacharoen, A., Chen, B., Mazières, D. "A Low-Bandwidth Network File System"(ACM SOSP '01). Ссылка: https://dl.acm.org/doi/10.1145/502034.502052

Анализ содержания: Фундаментальная работа, представившая сетевую файловую систему LBFS и заложившая основы алгоритмов контентно-определяемого разбиения (CDC) с использованием плавающего окна и полиномиального хеширования Рабина. В отличие от разбиения на блоки фиксированного размера, CDC устойчив к локальным вставкам и удалениям байтов (boundary-shift problem).

Значение для исследования: LBFS задаёт нижний эталон разбиения

потока на блоки. В рамках проекта `marline` CDC используется как предварительный этап перед скетчированием, поэтому понимание механики плавающего окна необходимо для оценки дисперсии длин чанков.

Xia, W., Jiang, H., Feng, D., et al. "FastCDC: a Fast and Efficient Content-Defined Chunking Approach for Data Deduplication"(USENIX ATC '16). Ссылка: https://www.usenix.org/conference/atc16/technical-sessions/presentation/xia
Анализ содержания: Авторы представляют FastCDC — современный стандарт разбиения данных, в котором тяжелое хеширование Рабина заменено легковесной функцией Gear с предварительно сгенерированными таблицами подстановки, а границы блоков определяются с помощью масок с динамическим переключением битов для нормализации распределения размеров блоков вокруг целевого среднего.
Значение для исследования: В модуле `marline_palantir` алгоритм FastCDC используется в качестве штатного чанкера. Нормализация размера блока критически важна, так как асимметрия длин сравниваемых чанков существенно снижает эффективность последующего дельта-кодирования.

MacDonald, J. P. "File System Support for Delta Compression"(RFC 3284, VCDIFF). Ссылка: https://datatracker.ietf.org/doc/html/rfc3284
Анализ содержания: Стандарт кодирования межфайловых различий (дельта-сжатия). Описывает принципы адресации копируемых сегментов (COPY) и непосредственных данных (ADD/RUN) относительно базового блока.
Значение для исследования: Дельта-энкодер GDelta, применяемый в конвейере скраббинга `marline`, реализует модифицированную блочную жадную адресацию различий. Анализ формата необходим для обоснования накладных расходов заголовка дельты на малых блоках.

2. Методы обнаружения сходства и локально-чувствительного хеширования (LSH)

Broder, A. Z. "On the resemblance and containment of documents"(IEEE SEQUENCES '97). Ссылка: https://ieeexplore.ieee.org/document/666900
Анализ содержания: Классическая статья, впервые предложившая алгоритм Min-Hash и доказавшая теорему о том, что вероятность совпадения минимальных значений хеш-функции от двух множеств k-грамм в точно-

сти равна коэффициенту сходства Жаккара:

$$P\left(\min(h(A)) = \min(h(B))\right) = J(A,B) = \frac{|A \cap B|}{|A \cup B|}. \quad (1)$$

Значение для исследования: Min-Hash составляет математическую основу генерации признаков (features) в скетч-индексах. Исследование свойств меры Жаккара обосновывает критерии выбора порога сходства при отсечении кандидатов.

Aronovich, L., Asher, R., Bachmat, E., et al. "The design of a similarity based deduplication system"(ACM SYSTOR '09). Ссылка: https://dl.acm.org/doi/10.1145/1534530.1534539
Анализ содержания: Архитектура промышленной системы SBC от исследователей IBM. Предложен подход вычисления спектра признаков блока: детерминированное хеширование Рабина используется для генерации P-признаков (position features) и C-признаков (content features). Похожими признаются блоки, имеющие совпадение хотя бы по одному супер-признаку.
Значение для исследования: Статья задаёт базовую архитектуру для модуля `marline_sketcher`. Она наглядно иллюстрирует проблему: даже при совпадении признака схожести итоговая дельта может оказаться непригодной (ложное срабатывание, False Positive), что обосновывает необходимость фильтрации кандидатов и штрафования неэффективных баз.

Li, Y., Jiang, H., Wang, K., et al. "Odess: A Fast and Lightweight Resemblance Detection Approach for Secondary Storage"(IEEE Transactio on Computers '18). Ссылка: https://ieeexplore.ieee.org/document/8416390
Анализ содержания: Алгоритм Odess ориентирован на устранение высоких накладных расходов на процессор и оперативную память при генерации скетчей. Вместо вычисления хеша для каждого байта авторы используют контентно-зависимую выборку (Content-Defined Sampling, CDS), формируя компактный эскиз из 3–4 признаков. Это снижает потребление RAM в 3–5 раз по сравнению со схемой Бродера.
Значение для исследования: Структура многоярусного скетч-индекса Palantir в проекте `marline` опирается на принципы Odess. Анализ работы позволяет выявить узкое место: при разреженном скетче (3–4 фичи) падает селективность инвертированного индекса, что приводит к разрастанию списков постингов.

Zhang, Y., Jiang, H., Wang, K., et al. "Finesse: Fine-Grained Feature Locality based Fast Resemblance Detection for Post-Deduplication Delta Compression"(USENIX FAST '19). Ссылка: https://www.us

enix.org/conference/fast19/presentation/zhang
Анализ содержания: Подход Finesse эксплуатирует свойство локальности признаков: вместо поиска глобального экстремума Min-Hash по всему чанку, блок делится на логические сегменты, внутри которых извлекаются локальные минимумы, объединяемые в супер-признаки. Это гарантирует выявление сходства даже при существенных локальных перестановках данных.
Значение для исследования: Подтверждает продуктивность агрегации фичей в супер-признаки и даёт концептуальную базу для многоуровневого фильтра ложных кандидатов.

3. Методы ускорения поиска по инвертированному индексу

Bayardo, R. J., Ma, Y., Srikant, R. "Scaling up all pairs similarity search"(ACM WWW '07). Ссылка: https://dl.acm.org/doi/10.1145/1242572.1242591
Анализ содержания: В статье предложен алгоритм All-Pairs и строго доказана концепция префиксной фильтрации (Prefix Filtering). Если требуется найти векторы с пересечением не менее k, достаточно просканировать только первые $(m - k + 1)$ признаков при условии упорядочивания признаков по возрастанию их глобальной частоты (документной частоты, Document Frequency, DF). Оставшиеся признаки проверяются только для верификации уже найденных кандидатов.
Значение для исследования: Служит математическим фундаментом реализованной в `marline_index` связки эвристик `rare_first` и `min_jaccard`, исключая необходимость полного сканирования длинных постингов частых признаков.

Broder, A. Z., Carmel, D., Herscovici, M., et al. "Efficient query evaluation using a two-level retrieval process"(ACM CIKM '03). Ссылка: https://dl.acm.org/doi/10.1145/956863.956944
Анализ содержания: Авторы вводят алгоритм WAND (Weak AND) для систем информационного поиска. Метод поддерживает динамическую верхнюю границу релевантности для кандидатов и выполняет опережающий переход по спискам постингов, пропуская документы, которые заведомо не смогут превзойти текущий порог отсечения.
Значение для исследования: Обосновывает целесообразность динамического раннего выхода (early exit) при накоплении весов кандидатов в инвертированном индексе.

Manning, C. D., Raghavan, P., Schütze, H. "Introduction to Information Retrieval"(Cambridge University Press, Глава 7: Computing scores in a complete search system). Ссылка: https://nlp.stanford.edu/IR-book/pdf/irbookonlinereading.pdf
Анализ содержания: Академическое руководство по архитектуре инвертированных индексов. Подробно анализируется закон Ципфа для распределения частот термов и математически доказывается необходимость фильтрации высокочастотных термов (heavy tail cutoff) для предотвращения деградации времени отклика.
Значение для исследования: Обосновывает необходимость внедрения эвристики `max_df` в модуль скетч-индекса `marline_index`.

4. Промышленные системы и инструменты дедупликации

В современной индустрии систем хранения данных выделяются несколько открытых и промышленных решений:

- **BorgBackup и Restic:** Популярные открытые системы резервного копирования на базе CDC (Borg использует кастомный алгоритм скользящего окна, Restic — модификацию FastCDC). Обе системы эффективно исключают точные дубликаты, однако полностью игнорируют схожие блоки. В версионных репозиториях исходного кода до 25–35% дискового пространства занимают квази-дубликаты (блоки с единичными правками), остающиеся необработанными.

- **ZFS Deduplication:** Реализация блочной дедупликации на уровне файловой системы. Использует хеш-таблицу точных совпадений (Deduplicati Table, DDT). Главная проблема ZFS — экспоненциальный рост требований к оперативной памяти: при вымывании DDT на диск производительность I/O падает на два порядка.

- **Проект Marline (Palantir):** Высокопроизводительная модульная платформа дедупликации на языке Rust, разрабатываемая в рамках исследовательской лаборатории. Архитектура объединяет чанкинг FastCDC, многоярусный скетч-индекс схожести и конвейер дельта-компрессии GDelta со сжатием Zstd.